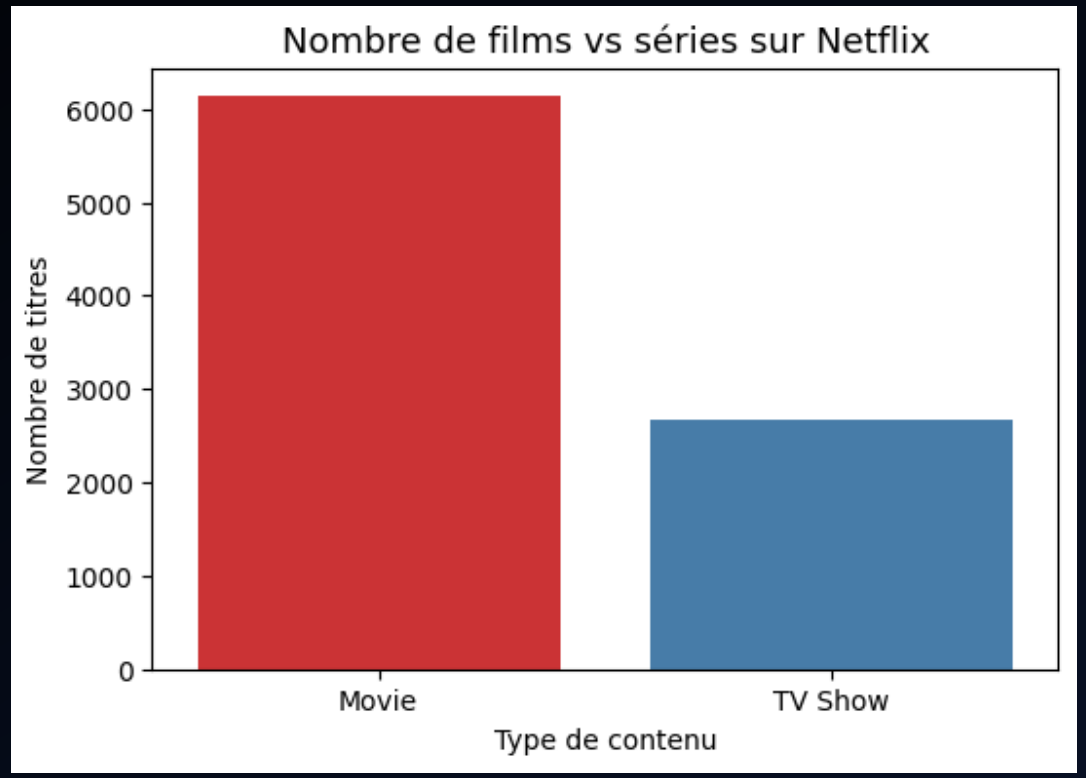
Projet datavisualisation

DATASETS FILMS ET SÉRIES DE NETFLIX

Importation des données et nettoyages

- J’ai commencé par importer les données depuis Kaggle sur le Datasets concernant les films et les séries proposés sur netflix
- Après cela j’ai décider d’analyser ces données avec plusieurs plots ce qui m’a permis d’avoir une vision différente pour toutes les données que j’ai étudié.
- Mais avant sa j’ai du les nettoyé pour pouvoir avoir de la données concrètes et générales.

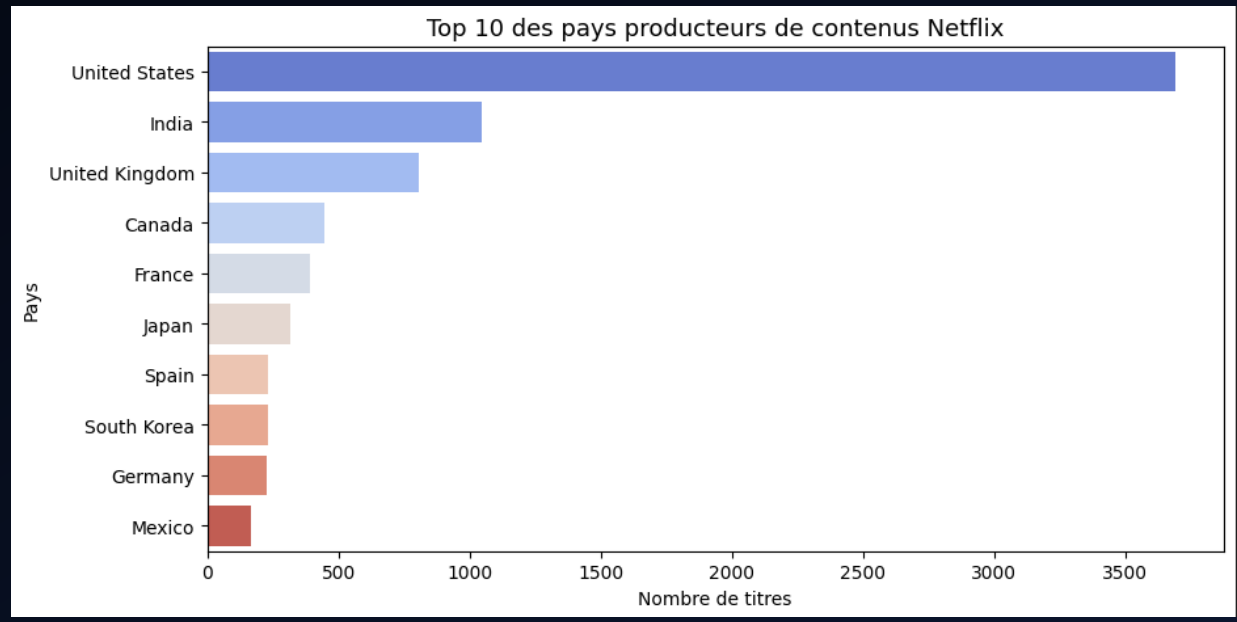
Analyse avec Countplot sur les films et séries.



- J’ai comparé le nombre de films contre le nombre de série présent dans ce dataset.
- Et nous pouvons apercevoir que nous avons un peu plus de 6000 films contre un peu moins de 3000 séries.
- On peut donc dire que nous plus du double en termes de nombre de film que de série.

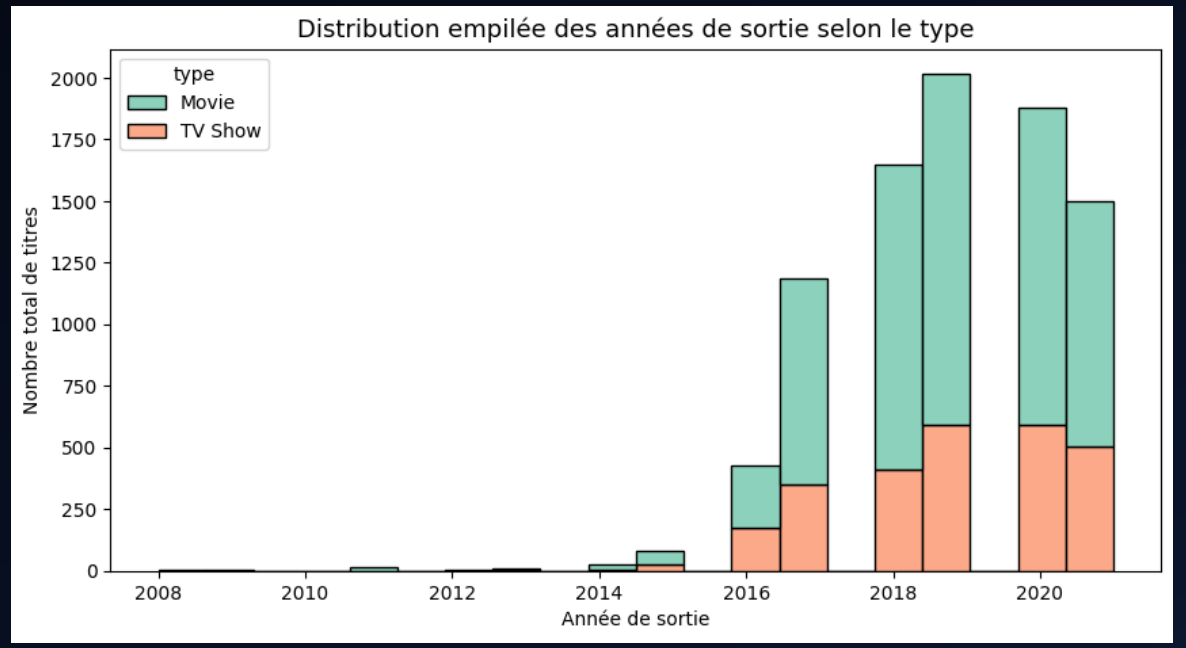
Analyse avec Barplot sur le nombre de contenus

- Ici j'ai analysé qui était les top producteurs pour les contenus netflix.
- Et on peut voir que les Etats-Unis on plus de 3500 contenus produits contre seulement un peu plus de 1000 pour l'Inde, suivi des autres pays aillant moins de 1000 contenus.
- On peut donc conclure que les Etats-Unis on presque un monopole sur la plateforme en termes de contenus.



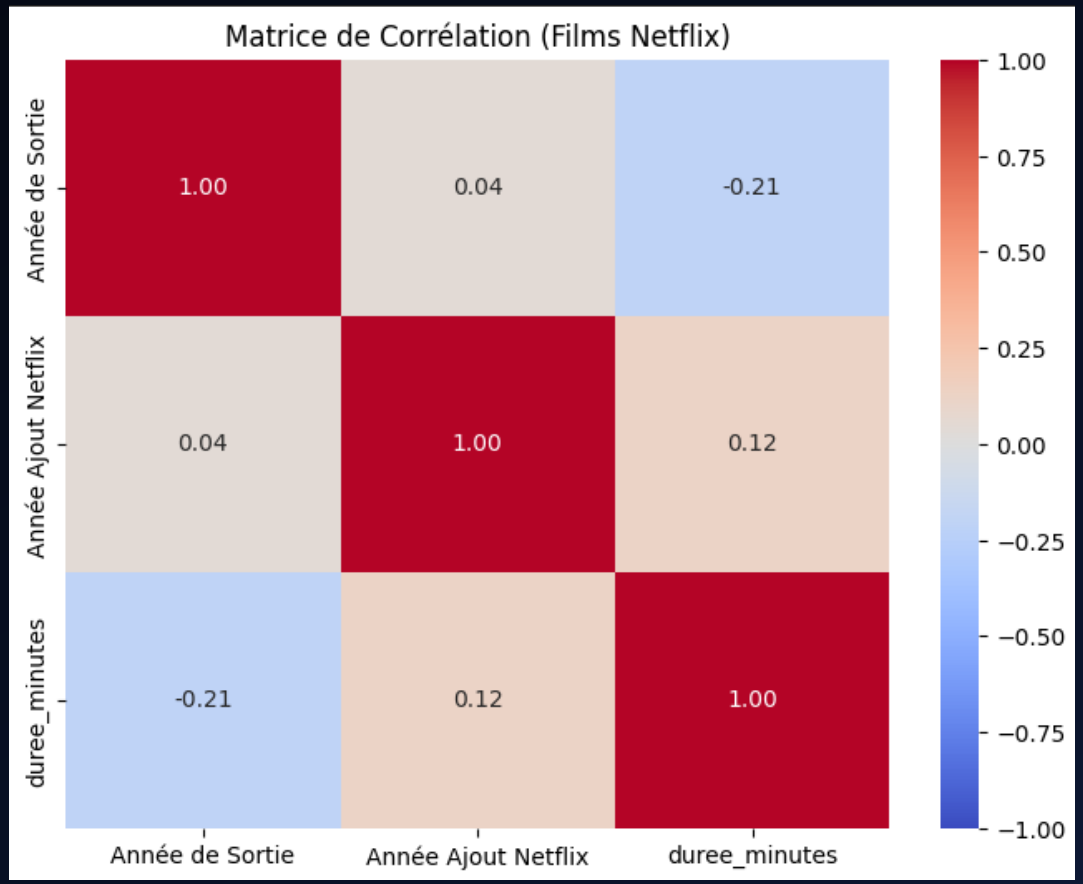
Analyse avec Histplot sur les années de sortie et le nombre de titre.

- Il s’agit ici des années de sortie des titres netflix.
- On peut voir que vers 2008 presque aucun titre qu’il soit film ou série n’était sortie
- Tandis que à partir de 2014 et 2015 on peut voir une proportion de film et série qui sortent mais inférieur à 250 titres.
- Or si l’on regarde 2020 nous avons une grosse proportion de films et série. Mais la proportion de films reste toujours plus élevée au fils des années.



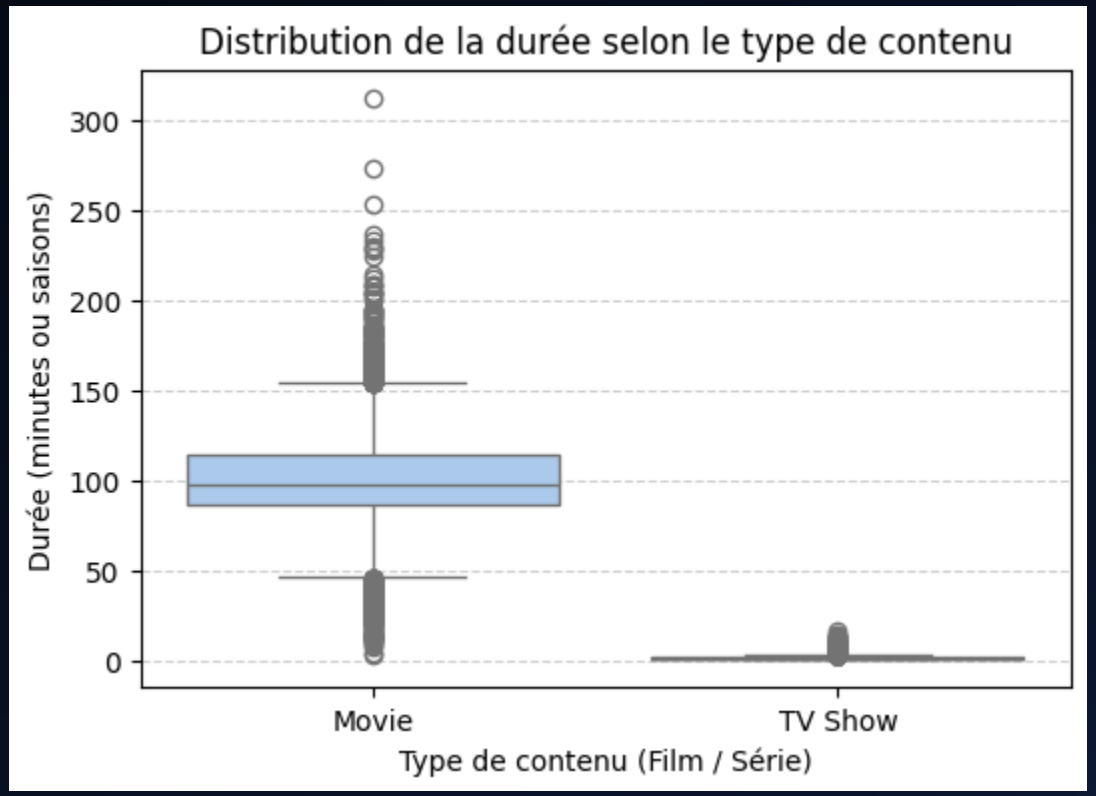
Analyse avec une matrice de corrélation grâce à une Heatmap

- Ici grâce à une matrice de correlation j'ai pu identifié s'il y avait un lien entre les variables quantitatives de ce dataset.
- Si une correlation tend vers 1 on dit que c'est une correlation positive parfaite et si elle tend vers -1 on dit que c'est une correlation négative parfaite. Et si elle tend vers 0 alors on dit que la correlation n'existe pas.
- Ici on peut voir que l'année de sortie et la durée en minute d'un films sur Netflix sont de -0,21 alors la corréation negative est faible. Pareil pour la durée en minute avec l'année d'ajout qui est de 0,12, c'est une correlation positive très faible.
- On peut donc conclure que la correlation des variables quantitatives n'existe presque pas.



Analyse avec un Boxplot sur la durée des films et des séries

- Grâce à un Boxplot, on peut identifié la durée moyenne des films et des séries, apercevoir certaines valeurs aberrantes et analyser les quartiles.
- On peut apercevoir ici concernant les films que un film dure en moyenne 100 minutes.
- Or pour les séries pour un boxplot il est trop dure pour nous d'analyser ses données, puisque les séries durent en moyenne le même nombre de saison donc tout est presque empilé. Le boxplot n'est pas adapté pour les séries mais plus pour les films. Ce qu'on dire c'est que aucune série ne dure plus de 25 saisons. Et que en moyenne une série dure environs 1 à 2 saisons.



Première question d’analyse

Domination géographique : Quels pays dominent la production Netflix ? Identifier les principaux producteurs de contenu et leur contribution relative au catalogue global.

Les Etats unies dominent la production Netflix avec un total de 3690 (environs 36%) de contenus, suivi de l’Inde avec 1046 (environs 10%) et de l’Angleterre avec 806 (environs 8%).

Deuxième question d’analyse

- Évolution temporelle : Comment évolue la quantité de contenu publié dans le temps ? Analyser les tendances de croissance et les périodes clés d'expansion.

Elle augmente d’année en année exponentiellement et il y a une tendance en 2018 ou elle atteint le plus haut qui correspond à sa période d’expansion.

Troisième question d’analyse

Comparaison : La durée des films sont-ils en moyenne plus longs que les séries ? Comparer les distributions de durée entre les deux types de contenu.

Les films sont en moyenne plus long mais si on prend en compte toute une saison d’une série non.

Conclusion de ce dataset

- Pour conclure l’analyse de ce dataset. Nous pouvons dire que grâce aux graphiques faits via des codes sur un notebook Jupyter, nous avons pus voir que en utilisant différent graphique adapté à différente données que cela rendait la données plus interprétables et plus faciles à analyser. Nous avons pus voir des corrélations entre données, comparé le nombre de films contre le nombre de série, mais aussi la durée moyenne d’un film ou d’une série. Et suivre une évolution du contenu de films et séries sur la plateforme Netflix.